



UNIVERSITÉ  
**PARIS**  
**DESCARTES**



UNIVERSITÉ PARIS DESCARTES

## PROJET PLURIDISCIPLINAIRE-MLSD

# BIOMEDICAL NAMED ENTITY RECOGNITION

*Team:*

ABIDAR BOUCHRA

BOUSSEBAINE MUSTAPHA

LARBI ABDERRAHMANE

*Teacher:*

AFFELDT SEVERINE

2019-2020

---

# CONTENTS

<b>1</b>	<b>Introduction</b>	<b>3</b>
<b>2</b>	<b>Les algorithmes utilisés</b>	<b>4</b>
2.1	CRF . . . . .	4
2.1.1	CRF théoriquement . . . . .	4
2.1.2	CRF techniquement . . . . .	5
2.2	BiLSTM-CNN-CRF . . . . .	5
2.2.1	BiLSTM-CNN-CRF théoriquement . . . . .	5
2.2.2	BiLSTM-CNN-CRF techniquement . . . . .	6
2.3	Bert . . . . .	7
2.3.1	Flair . . . . .	8
2.4	Spacy . . . . .	10
<b>3</b>	<b>Les données</b>	<b>11</b>
<b>4</b>	<b>Étude comparative</b>	<b>13</b>
<b>5</b>	<b>Modèle généralisé</b>	<b>15</b>
<b>6</b>	<b>Amélioration possibles</b>	<b>17</b>
6.1	L'ajout des features . . . . .	17
6.2	Changement d'architecture . . . . .	17
6.3	Apprentissage continuée . . . . .	17
<b>7</b>	<b>conclusion</b>	<b>19</b>
	<b>References</b>	<b>20</b>

# 1

---

## INTRODUCTION

La reconnaissance d'entités nommées trouve leurs origines dans le domaine de la linguistique. Alors considérées comme sous-tâches de l'extraction d'information, ces disciplines ont rapidement attiré l'attention de différents domaines scientifiques tels que la biologie et la biomédecine. Avec le volume important des connaissances médicales numérisées à large échelle, retrouver automatiquement une information de haute précision est devenu un défi.

La reconnaissance biomédicale des entités nommées (Bio-NER) est une tâche fondamentale dans la gestion des termes textuels biomédicaux importants tels que les maladies, les gènes, les produits chimiques.

L'ensemble des études présentées dans ce document, s'intéressent principalement à expérimenter les approches algorithmiques profonds en se basant sur les entités présentes sur différents corpus biomédicales.

Ce manuscrit est organisé selon quatre grandes parties. Nous commencerons par définir l'ensemble des algorithmes utilisés, ensuite les différents corpus expérimentés. Nous exploiterons ainsi les résultats obtenus sous forme d'une étude comparative. Puis nous présenterons un modèle que nous avons entraîné sur un corpus regroupant trois différentes thématiques. Ces dernières résumant l'ensemble des travaux réalisés jusqu'à présent. Néanmoins, nous finirons par proposer quelques techniques trouvées dans la littérature du NER pour améliorer la précision de la détection des entités nommées Biomédical.

# 2

---

## LES ALGORITHMES UTILISÉS

### 2.1 CRF

#### 2.1.1 CRF THÉORIQUEMENT

Les conditional Random Fields (ou CRF) sont des modèles Markoviens conditionnels qui ont été proposés pour remédier à certains défauts des modèles Markoviens plus classiques. Ils peuvent être appliqués à des données séquentielles, des données de type arbre et de façon plus générale à tout type de données structurées.

Les CRFs prennent comme entrées des données séquentielles avec une prise en compte de contexte précédent lors des prédictions sur un point de données. Nous modélisons mathématiquement cet aspect par "*features de connaissances*" définies comme suite :

$$f(X, i, l_{i-1}, l_i) \quad (1)$$

Le but de *features de connaissances* est de caractériser la séquence. Elle se base sur l'étiquette du mot précédent et du mot actuel. La construction du champ conditionnel est faite en attribuant à chaque *features de connaissances* un ensemble de poids ( $\lambda$ ) que l'algorithme va apprendre. La fonction suivante explique la distribution de probabilité pour les champs aléatoires conditionnels CRF [1].

$$P(y, X, \lambda) = \frac{1}{Z(X)} \exp^{\sum_{i=1}^n \sum_j \lambda_j f_i(X, i, y_{i-1}, y_i)} \quad (2)$$

et :

$$Z(X) = \sum_{y' \in Y} \sum_{i=1}^n \sum_j \lambda_j f_i(X, i, y'_i - 1, y'_i) \quad (3)$$

Les champs aléatoires conditionnels définissent les fonctions d'entité nécessaires, en initialisant les poids à des valeurs aléatoires, puis ils utilisent la descente de gradient de manière itérative jusqu'à la convergence des  $\lambda$ . L'équation de la mise à jour finale de descente de gradient pour

CRF est défini par l'équation (2) [1]:

$$\lambda = \lambda + \alpha \left[ \sum_{k=1}^m F_j(y^k, x^k) + \sum_{k=1}^m P(y|x^k, \lambda) F_j(y, x^k) \right] \quad (4)$$

Les CRF sont similaires à la régression logistique, car ils utilisent la distribution de probabilité conditionnelle. La différence est que l'algorithme CRF utilise "features de connaissances" comme entrées séquentielles.

Pour résumer, nous présenterons une synthèse d'utilisation un CRF.

- Il faut fournir des exemples  $(x, y)$ .
- Il faut redéfinir sous forme de features ses connaissances.
- Il faut lancer l'apprentissage des K poids  $\lambda_k$ :
  1. En maximisant la log-vraisemblance
  2. Méthode : descente de gradient
- Une fois le modèle fixé, il permet de trouver l'annotation  $y$  qui maximise  $p(y|x)$  pour tout nouveau  $x$ .

### 2.1.2 CRF TECHNIQUEMENT

Pour tester cette approche, nous avons expérimenté deux packages : *sklearn\_crfsuite* et *pycrfsuite*. L'objectif est de pouvoir comparer les scores de performances des modèles.

Pour rajouter des informations aux différents corpus, nous avons utilisé le package *NLTK* pour avoir les entités *POS*. Les différentes expérimentations de CRF sur les corpus de thématiques différents (maladies, gênes et produits chimiques) existent dans le repot git: [code](#).

## 2.2 BiLSTM-CNN-CRF

### 2.2.1 BiLSTM-CNN-CRF THÉORIQUEMENT

Les études [2] ont montré que CNN est une approche efficace pour extraire des informations morphologiques (comme le préfixe ou le suffixe d'un mot) à partir de caractères de mots (figure 1).

Pour de nombreuses tâches d'étiquetage séquentiel, il est avantageux d'avoir accès aux deux contextes : passés et futurs. Cependant, une solution élégante dont l'efficacité a été prouvée par des travaux antérieurs [3] est le LSTM bidirectionnel (BLSTM).

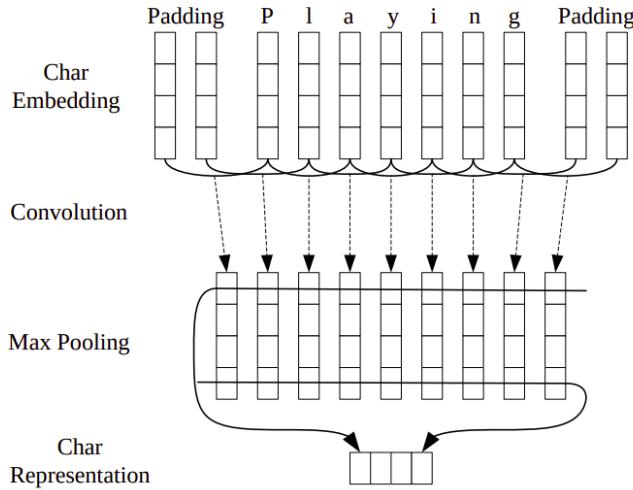


Figure 1: CNN pour l'extraction de représentations de mots au niveau des caractères.

L'idée de base est de présenter chaque séquence en avant et en arrière dans deux états cachés distincts afin de saisir les informations passées et futures, respectivement. Ensuite, les deux états cachés sont concaténés pour former le résultat final. La figure(2) illustre l'architecture d'un BiLSTM [4]. Vous pouvez consulter l'ensemble d'expérimentation réalisé par l'équipe dans le dépôt git [code](#).

Le modèle BiLSTM-CNN-CRF utilise ces deux architectures :

- Encodeur CNN pour la représentation embeddings.
- LSTM bidirectionnel pour le codage au niveau du mot.
- Champs aléatoires conditionnels (CRF) pour le décodage de sortie.

La figure(3) présente l'architecture de modèle BiLSTM-CNN-CRF.

### 2.2.2 BiLSTM-CNN-CRF TECHNIQUEMENT

Nous avons implémenté l'architecture BiLSTM CNN CRF en utilisant Keras Tensorflow. Nous avons utilisé le codage par CNN pour le codage par réseau neuronal à convolution pour la représentation des mots au niveau des caractères, le LSTM bidirectionnel pour le codage au niveau des mots et les champs aléatoires conditionnels (couche CRF) pour les décodages de sortie.

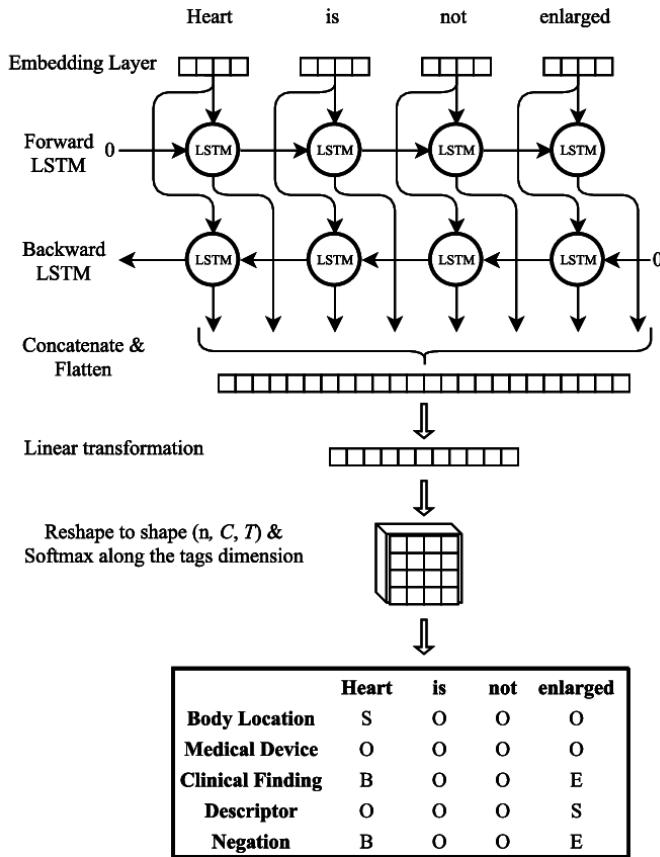


Figure 2: L'architecture de BLSTM

## 2.3 BERT

Bert a été présenté par Google. Ce modèle implémente plusieurs mécanismes notamment : *Transformer* et *Masked LM (MLM)*.

*Transformer* apprend les relations contextuelles entre les mots dans un texte[5]. Ce mécanisme contient deux parties : encodeur qui lit l'entrée de texte et décodeur pour prédire. Le mécanisme *Transformer* permet au modèle d'apprendre le contexte d'un mot en se basant sur l'ensemble de son environnement (gauche et droite du mot). Contrairement aux modèles directionnels, qui lisent l'entrée de texte séquentiellement (de gauche à droite ou de droite à gauche).

La deuxième stratégie qui rend Bert puissant est l'opération *Masked LM (MLM)*. Ce mécanisme permet de masquer 15% des mots de chaque séquence. Le modèle tente ensuite de prédire la valeur d'origine des mots masqués, sur la base du contexte (*Transformer*) fourni par les autres mots non masqués de la séquence (figure(4)).

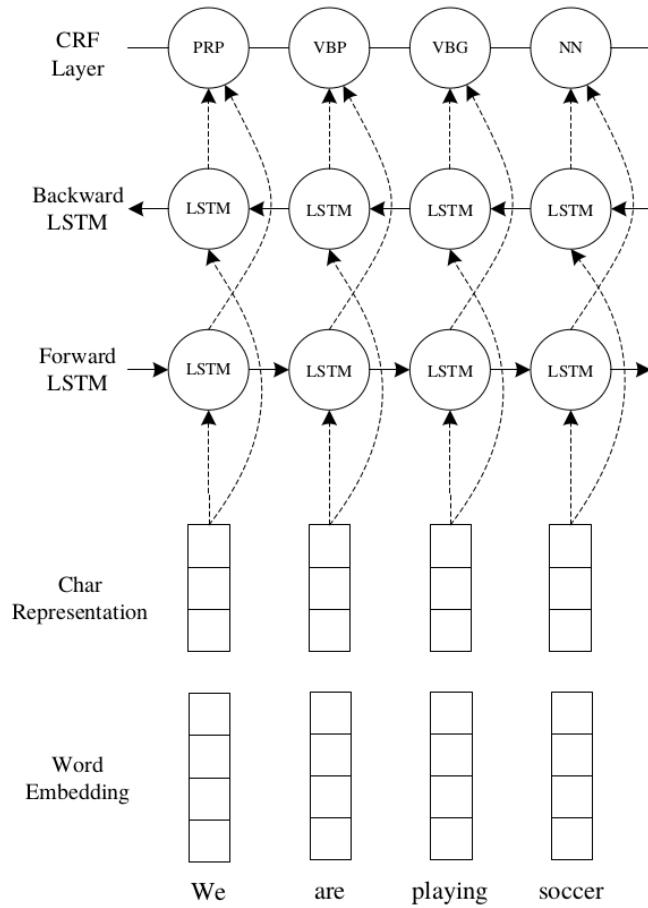


Figure 3: L'architecture de BLSTM-CNN-CRF[2]

### 2.3.1 FLAIR

Flair s'appuie sur une modélisation du langage neuronale au niveau des caractères pour apprendre des représentations contextuelles puissantes du langage humain à partir de grands corpus. La figure(5) présente l'architecture générale de Flair. Dans l'architecture de Flair, une phrase est vue en tant que séquence de caractères dans un modèle de langage de caractères bidirectionnel ML (Partie jaune de figure (5)) qui a été entraîné sur de très grands corpus de textes non étiquetés. À partir de ce LM, nous récupérons word a contextual embedding en enregistrant les états de la cellule du premier et du dernier caractère. Ce word embedding est ensuite passé dans un séquence BiLSTM-CRF vanille (bleu dans la figure 5 ).

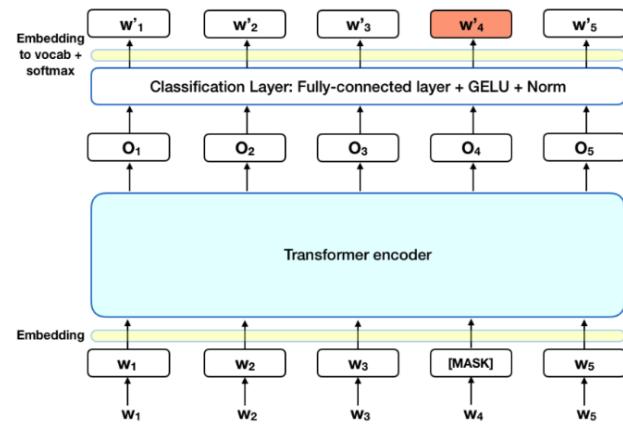


Figure 4: Mécanisme du Masked LM[5]

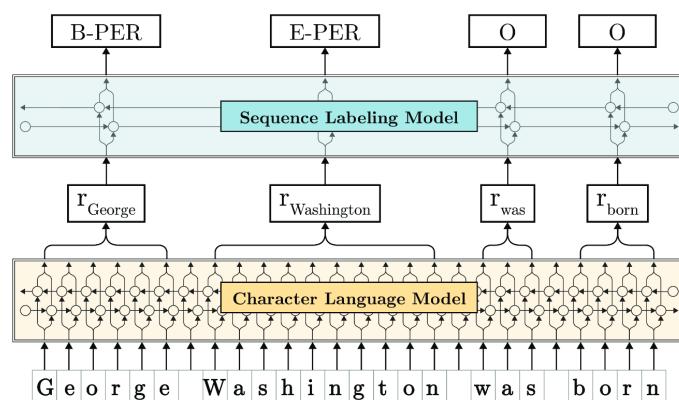


Figure 5: L'architecture de Flair [6]

## 2.4 SPACY

Spacy est un outil pour la déction des NER. Il prend des décions sur une base d'une prédition entrainée pendant l'apprentissage. La figure suivant(figure 6) [10] explique le fonctionnement de spacy. Le format des données d'entraînement pour le modèle Spacy est différent de ceux

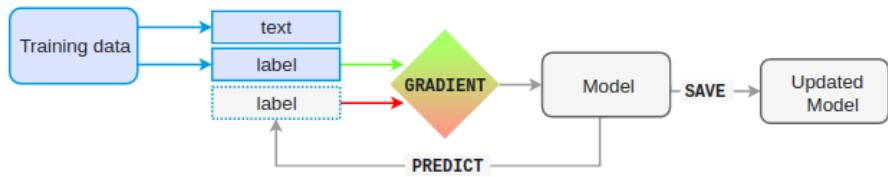


Figure 6: Le fonctionnement de spacy[10]

d'autres modéles. D'où la nécessité de procéder à une étape de pre-processing. Un fichier `helper.py` présent dans le repôt git [code](#) contient les différents fonctions permettant de convertir automatiquement les données sous le format adapté aux inputs Spacy.

Dans l'utilisation de Spacy, la seule métrique qui évalue le modèle est *Loss(resultat de loss)*. Les graphes suivants expliquent l'évolution de loss en fonction des epochs

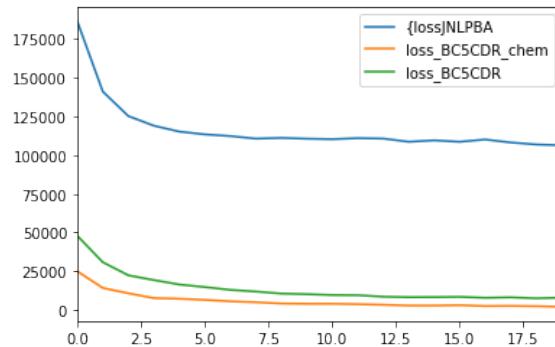


Figure 7: Loss spacy

# 3

---

## LES DONNÉES

L'ensemble de données utilisées dans cette étude sont présentées dans le tableau ci-dessous (Table.1). Chaque corpus présente une thématique lié à un domaine bio-Médical notamment : les maladies, gènes, protéines et les produits chimiques.

DataSets					
corpus	Type d'Entité	Phrases	annotations	Taille	Publication
NCBI	Diseases	7639	6881	793	<a href="#">source</a>
BC5CDR	Diseases	14228	12852	1500	<a href="#">source</a>
JNLPBA	Genes	22562	35336	2404	<a href="#">source</a>
BC5CDR-chem	Chemicals	14228	15935	1500	<a href="#">source</a>

Table 1: Données d'entraînement

Les captures d'écrans suivantes présentent les top features dans les corpus (*NCBI, BC5CDR, BC5CDR-chemical et JNLPBA*) avec une estimation des poids associées([code](#))

y-B-Disease top features		y-E-Disease top features		y-I-Disease top features		y-S-Disease top features	
Weight	Feature	Weight	Feature	Weight	Feature	Weight	Feature
-0.119	-1word lower dysphonia	-6.131	-word lower tumors	-5.897	-1word lower hyperthyroidism	-5.840	-word lower hypothyroidism
-4.239	-1word lower dyspnea	-5.289	-word lower cancers	-5.530	-1word lower neph	-5.600	-word lower carcinomas
-0.237	-word lower praderwilli	-4.842	-word lower reiteration	-5.132	-1word lower gastric	-5.434	-word lower cancers
-0.173	-1word lower hypoxia	-4.712	-word lower hypoxia	-4.866	-1word lower syndromic	-5.278	-word lower neurodegeneration
-0.173	-1word lower cerebral	-4.414	-word lower wasting	-4.502	-1word lower fingers	-5.010	-word lower hypomyelination
-0.173	-1word lower hypoxia	-4.386	-word lower hypoxia	-4.532	-1word lower limbs	-5.010	-word lower hypothymia
-0.039	-word lower vomiting	-4.142	-word lower 3mins	-4.291	-1word lower linked	-4.903	-word lower 3mins
-0.018	-1word lower deficiencies	-4.142	-word lower hypothyroidism	-4.210	-1word lower syndrome	-4.825	-word lower obesity
-0.018	-1word lower deficiencies	-4.081	-word lower anchored	-4.128	-1word lower hypothyroid	-4.745	-word lower gastroenter
-0.326	-1word lower retardation	-4.081	-word lower junks	-4.128	-1word lower component	-4.329	-word lower 3jps
-3.808	-1word lower defects	-3.950	-1word lower vom	-4.118	-1word lower merzbacher	-4.269	-word lower tumour
-3.795	-1word lower cancer	-3.803	-word lower diseas	-4.118	-1word lower well	-4.211	-word lower hypoglycemia
-3.795	-1word lower cancer	-3.803	-word lower hypoxia	-4.081	-1word lower well	-4.100	-word lower hypoxia
-3.769	-1word lower staxis	-3.835	-word lower neoplasia	-4.008	-1word lower palas	-4.106	-word lower cancer
-3.769	-1word lower cerebral	-3.787	-word lower wellbrand	-4.000	-1word lower ovari	-4.083	-word lower infiltrate
-3.740	-1word lower hypoxia	-3.787	-word lower wellbrand	-3.982	-1word lower inhibit	-4.047	-word lower 3ANN
-3.740	-1word lower hypoxia	-3.765	-1word lower linked	-3.928	-1word lower inborn	-4.047	-word lower inborn
-3.667	-1word lower deficiency	-3.749	-1word lower ovarian	-3.918	-1word lower anchored	-4.047	-word lower inborn
-14.199	-1word lower hypoxia	-3.749	-1word lower hypoxia	-3.918	-1word lower hypoxia	-4.047	-word lower inborn
-14.199	-1word lower hypoxia	-14.199	-more positive ..	-14.199	-more positive ..	-14.199	-more positive ..
-14.199	-1word lower hypoxia	-14.199	-more positive ..	-14.199	-more positive ..	-14.199	-more positive ..

Figure 8: NCBI *top features*

y-B-Chemical top features		y-3'-Chemical top features		y-B-Disease top features		y-3'-Disease top features	
Weight	Feature	Weight	Feature	Weight	Feature	Weight	Feature
-.559	1-[1-(4-methylphenyl)propoxy]antidepressant	-.542	1-[word lower(1)_lower]berrier	-.530	1-[word lower(1)_lower]vomiting	-.530	1-[word lower(1)_lower]vomiting
-.359	1-[word lower(1)_lower]propoxyn	-.5328	1-[word lower(1)_lower]cad	-.564	1-[word lower(1)_lower]hypotension	-.5005	1-[word lower(1)_lower]infection
.6899	1-word(3)_1[word]	-.4935	1-word(3)_1[word]	-.504	1-word(3)_1[word]	.9484	1-word(3)_1[word]
-.134	1-word(3)_1[word]lumin	-.4936	1-word(3)_1[word]methyl	-.504	1-word(3)_1[word]	-.896	1-word(3)_1[word]
.134	1-word(3)_1[word]antidepressants	-.4748	1-word(3)_1[word]berries	-.334	1-word(3)_1[word]pare	-.896	1-word(3)_1[word]emboli
.5887	1-word(3)_1[word]lower(1)_oxide	-.4476	1-word(3)_1[word]berries	-.185	1-word(3)_1[word]depressed	.819	1-word(3)_1[word]disorder
.5665	1-word(3)_1[word]3-1[word]	-.4477	1-word(3)_1[word]contraceptives	-.116	1-word(3)_1[word]hypertension	-.448	1-word(3)_1[word]uried
.5667	1-word(3)_1[word]3-1[word]	-.2448	1-word(3)_1[word]3-ide	-.088	1-word(3)_1[word]hypotension	.4483	1-word(3)_1[word]ureter
.5565	1-word(3)_1[word]lower(1)_contraceptives	.4218	1-[word lower(1)_lower]cladonony	.969	1-word(3)_1[word]ALL	.4474	1-word(3)_1[word]colon
.5453	1-word(3)_1[word]lower(1)_contraceptives	-.0490	1-[word lower(1)_lower]carboxyle	.969	1-word(3)_1[word]toxicity	.4474	1-word(3)_1[word]colon
.5453	1-word(3)_1[word]	-.0490	1-[word lower(1)_lower]carboxyle	.814	1-word(3)_1[word]seizures	.276	1-word(3)_1[word]seizures
.5422	1-word(3)_1[word]3-1[word]	.0006	1-word(3)_1[word]antidepressants	.765	1-word(3)_1[word]seizures	.4199	1-word(3)_1[word]infected
.5018	1-word(3)_1[word]lower(1)_acid	.9399	1-[word lower(1)_lower]aliquating	.587	1-word(3)_1[word]epileptic	.4195	1-word(3)_1[word]infected
.4762	1-word(3)_1[word]lower(1)_phenobarbital	.3884	1-[word lower(1)_lower]buty	.587	1-word(3)_1[word]confusion	.4105	1-word(3)_1[word]midline
.4733	1-word(3)_1[word]lower(1)_glutamate	.3884	1-[word lower(1)_lower]buty	.553	1-word(3)_1[word]deform	.4135	1-word(3)_1[word]midline
.4660	1-word(3)_1[word]	.3792	1-[word lower(1)_lower]azoxazole	.553	1-word(3)_1[word]syndrome	.3965	1-word(3)_1[word]syndrome
.4660	1-word(3)_1[word]	.3787	1-[word lower(1)_lower]berrier	.553	1-word(3)_1[word]vomiting	.3992	1-word(3)_1[word]verbal
.4578	1-word(3)_1[word]lower(1)_bilirubin	.3775	1-[word lower(1)_lower]esters	.086	1-word(3)_1[word]vomiting	.3972	1-word(3)_1[word]create
.4578	1-word(3)_1[word]lower(1)_bilirubin	.3775	1-[word lower(1)_lower]esters	.221	1-word(3)_1[word]more	.3972	1-word(3)_1[word]create
.178	1-word(3)_1[word]more	.104	10-more	.221	1-word(3)_1[word]more	.155	15-more
.178	1-word(3)_1[word]more	.104	10-more	.221	1-word(3)_1[word]more	.155	15-more
.178	1-word(3)_1[word]more	.104	10-more	.221	1-word(3)_1[word]more	.155	15-more

Figure 10: BC5CDR *chemical top features*

y-B-DNA top features		y-E-DNA top features		y-tDNA top features		y-s-DNA top features	
Weight	Feature	Weight	Feature	Weight	Feature	Weight	Feature
-5.842	1-word lower genes	-0.001	1-word lower sites	-0.001	1-word lower homocompatibility	-0.803	word lower s-elimination
-5.842	1-word lower many	-0.054	1-word lower q22	-0.977	1-word lower homogenes	-0.803	word lower s-elimination
-5.080	1-word lower other	-0.052	1-word lower d+	-0.789	1-word lower kappaB	-0.859	word lower s-site
-4.953	1-word lower protocancer	-0.553	1-word lower proto-oncogenes	-0.766	1-word lower promoters	-0.590	word lower t-site
-4.728	1-word lower reporter	-0.262	1-word lower q14	-0.145	1-word lower hstcompatibility	-0.455	word lower oncogenes
-4.715	1-word lower respective	-0.261	1-word lower q32	-0.025	1-word lower c-rich	-0.455	word lower germinal
-4.692	1-word lower genomes	-0.505	1-word lower q33	-0.025	1-word lower c-poor	-0.455	word lower s-regions
-4.543	word lower retinoblastoma	-0.493	1-word lower purine-rich	-0.887	1-word lower site-like	-0.691	word lower 3-RES
-4.513	1-word lower distinct	-0.451	1-word lower artron	-0.812	1-word lower sites	-0.681	word lower chromatin
-4.484	1-word lower lncRNAs	-0.441	1-word lower proteins	-0.767	1-word lower sites+parent	-0.681	word lower chromatin
-4.484	1-word lower ctna	-0.378	1-word lower sites	-0.767	1-word lower nucleoids	-0.379	1-word lower distinct
-4.362	1-word lower 360	-0.320	1-word lower constructs	-0.767	1-word lower sites+parent	-0.379	1-word lower immediate
-4.362	1-word lower plasmids	-0.320	1-word lower constructs	-0.767	1-word lower sites+parent	-0.260	word lower 3-12
-4.291	1-word lower coding	-0.287	1-word lower genes	-0.603	1-word lower motifs	-0.348	word lower 3-12
-4.250	1-word lower producers	-0.238	1-word lower q7p1	-0.551	1-word lower constructs	-0.241	word lower 3-region
-4.178	1-word lower sequences	-0.225	1-word lower vectors	-0.542	1-word lower constructs	-0.241	word lower 3-region
-4.136	1-word lower canva	-0.200	1-word lower lncRNAs	-0.391	1-word lower X-Y	-0.045	word lower 3-24
-4.107	word lower prior	-0.763	2423 more positive ...	-0.389	4389 more positive ...	-0.045	word lower z-p
... 3658 more positive ...		... 298 more negative ...		... 378 more negative ...		... 442 more negative ...	
... 37 more regions ...							
y-B-cell line top features		y-E-cell line top features		y-t-cell line top features		y-s-cell line top features	
Weight	Feature	Weight	Feature	Weight	Feature	Weight	Feature
-5.307	1-word lower t different	-0.519	1-word lower line	-0.081	1-word lower lines	-0.549	word lower t-thp1
-5.018	1-word lower t clones	-0.520	word lower lines	-0.473	1-word lower clones	-0.403	word lower prolymphocytes
-4.953	1-word lower t different	-0.519	1-word lower t clones	-0.473	1-word lower t clones	-0.435	word lower heterokaryons
-4.712	1-word lower t	-0.470	1-word lower mac	-0.650	1-word lower cultures	-0.003	word lower hexwicks
-4.678	1-word lower t primed	-0.414	1-word lower population	-0.635	1-word lower sk-in-b	-0.461	word lower t-CD
-4.647	1-word lower t	-0.414	1-word lower population	-0.635	1-word lower sk-in-b	-0.394	word lower t-CD
-4.560	1-word lower other	-0.366	1-word lower t92	-0.385	1-word lower hstcompatibility	-0.395	word lower t-cell2
-4.406	1-word lower t same	-0.342	1-word lower t17f	-0.318	1-word lower tcralpha	-0.383	word lower t-mot4
-4.362	1-word lower t different	-0.337	1-word lower t17f	-0.318	1-word lower tcrbeta	-0.349	word lower t-mot4
-4.331	1-word lower tine	-0.424	1-word lower hybridoma	-0.164	1-word lower t cells	-0.342	word lower t-mat
-4.290	1-word lower t cells	-0.125	1-word lower tone-13	-0.143	1-word lower t-transformed	-0.372	word lower tfcis
-4.200	1-word lower epo-	-0.005	1-word lower t cells	-0.012	1-word lower trophymagglutinin	-0.372	word lower tfcis
-3.988	1-word lower independent	-0.306	1-word lower transfectants	-0.395	1-word lower co-cultures	-0.316	word lower tmdmac
-3.903	1-word lower prickle	-0.306	1-word lower transfectants	-0.395	1-word lower t cells	-0.316	word lower tmdmac
-3.825	1-word lower t distinct	-0.323	1-word lower t104	-0.346	1-word lower hsx2-family	-0.353	word lower t-hela
-3.750	1-word lower t30	-0.323	1-word lower t104	-0.346	1-word lower hsx2-family	-0.347	word lower t-hela
-3.751	1-word lower t30+HIV	-0.365	1-word lower context	-0.319	1-word lower nonexpressing	-0.353	word lower t-CLs
-3.771	1-word lower t	-0.356	1-word lower context	-0.319	2610 more positive ...	-0.548	more positive ...
-3.751	1-word lower prickleacted	-0.155	1-word lower negative	-0.359	179 more negative ...	-0.306	more negative ...
... 142 more negative ...		... 159 more negative ...		... 179 more negative ...		... 306 more negative ...	
y-B-protein top features		y-E-protein top features		y-t-protein top features		y-s-protein top features	
Weight	Feature	Weight	Feature	Weight	Feature	Weight	Feature
-0.577	1-word lower t	-0.744	1-word lower (c-fos	-0.307	1-word lower superfamily	-0.703	word lower t-leukem
-5.487	1-word lower other	-0.628	1-word lower sbo	-0.452	1-word lower product	-0.889	word lower cytokines
-5.426	word lower c-kep-positive	-0.528	1-word lower sbo	-0.598	1-word lower proteases	-0.506	word lower alpha-helices
-5.045	1-word lower t	-0.523	1-word lower t	-0.475	1-word lower t	-0.479	word lower alpha-helices
-5.045	1-word lower factors	-0.523	1-word lower t	-0.475	1-word lower t	-0.479	word lower alpha-helices
-4.969	1-word lower receptors	-0.439	1-word lower waf1/p21	-0.478	1-word lower t	-0.436	word lower alpha-helices
-4.949	1-word lower t	-0.439	1-word lower waf1/p21	-0.478	1-word lower t	-0.436	word lower alpha-helices
-4.749	1-word lower t	-0.439	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.718	1-word lower synthesis	-0.426	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.637	1-word lower t	-0.426	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.628	1-word lower complex	-0.407	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.548	1-word lower t	-0.411	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.548	1-word lower different	-0.411	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.548	1-word lower t	-0.411	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.548	1-word lower t	-0.411	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.448	1-word lower t	-0.439	1-word lower t	-0.439	1-word lower t	-0.436	word lower alpha-helices
-4.380	1-word lower desertin	-0.437	1-word lower t	-0.439	1-word lower t	-0.436	word lower alpha-helices
-4.312	1-word lower t	-0.427	1-word lower t	-0.439	1-word lower t	-0.436	word lower alpha-helices
... 142 more negative ...		... 142 more negative ...		... 142 more negative ...		... 142 more negative ...	
y-B-protein top features		y-E-protein top features		y-t-protein top features		y-s-protein top features	
Weight	Feature	Weight	Feature	Weight	Feature	Weight	Feature
-0.577	1-word lower t	-0.744	positive	-0.307	1-word lower superfamily	-0.703	word lower t-leukem
-5.487	1-word lower other	-0.628	1-word lower t	-0.452	1-word lower product	-0.889	word lower cytokines
-5.426	word lower c-kep-positive	-0.528	1-word lower sbo	-0.598	1-word lower proteases	-0.506	word lower alpha-helices
-5.045	1-word lower t	-0.523	1-word lower t	-0.475	1-word lower t	-0.479	word lower alpha-helices
-5.045	1-word lower factors	-0.523	1-word lower t	-0.475	1-word lower t	-0.479	word lower alpha-helices
-4.969	1-word lower receptors	-0.439	1-word lower waf1/p21	-0.478	1-word lower t	-0.436	word lower alpha-helices
-4.949	1-word lower t	-0.439	1-word lower waf1/p21	-0.478	1-word lower t	-0.436	word lower alpha-helices
-4.749	1-word lower t	-0.439	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.718	1-word lower synthesis	-0.426	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.637	1-word lower t	-0.426	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.628	1-word lower complex	-0.407	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.548	1-word lower t	-0.411	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.548	1-word lower t	-0.411	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.548	1-word lower t	-0.411	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.448	1-word lower t	-0.439	1-word lower t	-0.439	1-word lower t	-0.436	word lower alpha-helices
-4.380	1-word lower desertin	-0.437	1-word lower t	-0.439	1-word lower t	-0.436	word lower alpha-helices
-4.312	1-word lower t	-0.427	1-word lower t	-0.439	1-word lower t	-0.436	word lower alpha-helices
... 142 more negative ...		... 142 more negative ...		... 142 more negative ...		... 142 more negative ...	
y-B-protein top features		y-E-protein top features		y-t-protein top features		y-s-protein top features	
Weight	Feature	Weight	Feature	Weight	Feature	Weight	Feature
-0.577	1-word lower t	-0.744	positive	-0.307	1-word lower superfamily	-0.703	word lower t-leukem
-5.487	1-word lower other	-0.628	1-word lower t	-0.452	1-word lower product	-0.889	word lower cytokines
-5.426	word lower c-kep-positive	-0.528	1-word lower sbo	-0.598	1-word lower proteases	-0.506	word lower alpha-helices
-5.045	1-word lower t	-0.523	1-word lower t	-0.475	1-word lower t	-0.479	word lower alpha-helices
-5.045	1-word lower factors	-0.523	1-word lower t	-0.475	1-word lower t	-0.479	word lower alpha-helices
-4.969	1-word lower receptors	-0.439	1-word lower waf1/p21	-0.478	1-word lower t	-0.436	word lower alpha-helices
-4.949	1-word lower t	-0.439	1-word lower waf1/p21	-0.478	1-word lower t	-0.436	word lower alpha-helices
-4.749	1-word lower t	-0.439	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.718	1-word lower synthesis	-0.426	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.637	1-word lower t	-0.426	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.628	1-word lower complex	-0.407	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.548	1-word lower t	-0.411	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.548	1-word lower t	-0.411	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.548	1-word lower t	-0.411	1-word lower t	-0.464	1-word lower t	-0.436	word lower alpha-helices
-4.448	1-word lower t	-0.439	1-word lower t	-0.439	1-word lower t	-0.436	word lower alpha-helices
-4.380	1-word lower desertin	-0.437	1-word lower t	-0.439	1-word lower t	-0.436	word lower alpha-helices
-4.312	1-word lower t	-0.427	1-word lower t	-0.439	1-word lower t	-0.436	word lower alpha-helices
... 142 more negative ...		... 142 more negative ...		... 142 more negative ...		... 142 more negative ...	

Figure 11: Genes top features

y=B-Chemical top features		y=C-Chemical top features		y=B-Disease top features		y=D-Disease top features	
Weight	Feature	Weight	Feature	Weight	Feature	Weight	Feature
+7.756	word_lower anti-depressant	+7.422	1 word_lower vitamin	+6.733	word_lower migraine	+6.130	word_lower vomiting
+5.399	word_lower topropurin	+6.935	1 word_lower card	+6.450	word_lower epilepsy	+4.902	word_lower infection
+4.273	word_lower lumiracizine	+4.935	word_lower card	+6.504	word_lower seizure	+3.984	word_lower inflammation
-6.134	word_lower lumiracizine anti-depressants	+4.836	1 word_lower methyl	+6.406	word_lower cancer	+4.904	1 word_lower 000
-5.183	word_lower lumiracizine acid	+4.478	1 word_lower berries	+6.535	word_lower depression	+4.785	1 word_lower embolic
+5.780	word_lower 3 jan	+4.423	1 word_lower lopinavir	+6.116	word_lower hypertension	+4.819	word_lower heart
+5.668	word_lower 3 jan acid	+4.277	word_lower contraceptives	+5.942	word_lower hypothyroid	+4.699	word_lower uterer
+5.565	word_lower 3 jan acid oil	+4.277	1 word_lower dexamethasone	+5.969	word_lower hypertensive	+4.488	word_lower disease
+5.565	1 word_lower contraceptives	+4.218	1 word_lower dexamethasone	+5.969	3 ALL	+4.488	word_lower disease
+5.532	word_lower 3 jan oil	+4.093	word_lower androgen	+5.892	word_lower toxicity	+4.474	1 word_lower coartation
+5.422	word_lower 3 jan oil acid	+4.093	1 word_lower androgen	+5.765	word_lower constipation	+4.315	1 word_lower parkinson
+5.422	word_lower 3 yr	+4.006	word_lower anti-depressants	+5.667	word_lower convulsive	+4.199	1 word_lower infect
+5.228	1 word_lower acid	+3.982	1 word_lower pregnan	+5.559	word_lower depression	+4.175	1 word_lower pain
+4.782	word_lower 3 jan oil phenoxybenzal	+3.982	1 word_lower pregnan	+5.559	word_lower confusion	+4.105	1 word_lower tendinitis
+4.782	word_lower 3 jan oil phenoxybenzal acid	+3.940	1 word_lower hormodex	+5.559	word_lower depression	+3.996	word_lower filtration
+4.747	word_lower glutamine	+3.799	1 word_lower 921	+5.553	word_lower delirium	+4.032	word_lower syndrome
+4.703	word_lower l-taurine	+3.792	1 word_lower imazoxanide	+5.407	word_lower seizures	+3.922	word_lower cerebral
+4.578	word_lower l-tyrosine	+3.783	1 word_lower hydroxyurea	+5.086	word_lower stroke	+3.972	1 word_lower creative
+4.578	word_lower l-threonine	+3.775	1 word_lower esters	+5.086	word_lower 3 yal	+3.956	1 word_lower cerebral
... 1749 more positive ...		... 1204 more positive ...		... 2117 more positive ...		... 1965 more positive ...	
... 1749 more positive ...		... 1204 more positive ...		... 2117 more positive ...		... 1965 more positive ...	

Figure 9: BC5CDR top features

12

# 4

---

## ÉTUDE COMPARATIVE

La table(2) résume les performances de détection d'entités de chaque algorithme.

En se basant sur la dispersion des classes, nous avons utilisé le *F1 Score* comme un indice de performance. Dans Les 4 corpus testés, FLair renvoie le meilleur score.

Table 2: La performances des modèles

Algorithmes		F1 score(%)
CRF	NCBI	77
	BC5CDR	75
	JNLPBA	70
	BC5CDR-chem	76
BiLSTM-CRF	NCBI	70
	BC5CDR	65
	JNLPBA	
	BC5CDR-chem	60
Flair	NCBI	88
	BC5CDR	88
	JNLPBA	81
	BC5CDR-chem	93

L'algorithme *BiLSTM-CRF* a donné les faibles scores pour la détection des produits chimiques et les maladies sur le corpus BC5CDR. Nous proposons dans la section 6 "Amélioration possibles" des techniques trouvées dans la littérature pour augmenter la performance.

Suite à un problème au niveau des ressources, nous n'avons pas réussi à entraîner le modèle BiLSTM-CRF sur le corpus JNLPBA.

Une tentative a été testée en diminuant la taille des corpus. Cette tentative n'a pas abouté aux résultats attendus : F1 score égale à 25%

L'exemple d'exécution des modèles sur des phrases différentes en temps réel est présenté dans la figure (12)

```
In [52]: print(doc_JNLBPA)
print("-----")
print("Tagged : ",NER_JNLBPA.predict(doc_JNLBPA)[0].to_tagged_string())
gene expression and NF-kappa B activation through CD28 requires reactive oxygen production by 5-lipoxygenase .
-----
Tagged : gene <E-DNA> expression and NF-kappa <B-protein> B <E-protein> activation through CD28 <S-protein> requires reactive oxygen production by 5-lipoxygenase <S-protein> .

In [53]: print("Sentance : ",doc_BC5CDR_chem)
print("-----")
print("Tagged : ",NER_BC5CDR_chem.predict(doc_BC5CDR_chem)[0].to_tagged_string())
Sentance : OBJECTIVES : The United Kingdom Parkinson ' s Disease Research Group ( UKPDRG ) trial found an increased mortality in patients with Parkinson ' s disease ( PD ) randomized to receive 10 mg selegiline per day and L - dopa compared with those taking L - dopa alone .
-----
Tagged : OBJECTIVES : The United Kingdom Parkinson ' s Disease Research Group ( UKPDRG ) trial found an increased mortality in patients with Parkinson ' s disease ( PD ) randomized to receive 10 mg selegiline <S-Chemical> per day and L <B-Chemical> - <I-Chemical> dopa <E-Chemical> compared with those taking L <B-Chemical> - <I-Chemical> dopa <E-Chemical> alone .

In [54]: print(doc_BC5CDR)
print("-----")
print("Tagged : ",NER_BC5CDR.predict(doc_BC5CDR)[0].to_tagged_string())
In the in vivo study , the administration ( 50 mg / kg , i . p . ) of TET and FAN in mice showed the inhibition of thrombosis by 55 % and 35 % , respectively , while acetylsalicylic acid ( ASA , 50 mg / kg , i . p . ) , a positive control , showed only 30 % inhibition .
-----
Tagged : In the in vivo study , the administration ( 50 mg / kg , i . p . ) of TET <B-Chemical> and FAN <B-Chemical> in mice showed the inhibition of thrombosis <B-Disease> by 55 % and 35 % , respectively , while acetylsalicylic <B-Chemical> acid <I-Chemical> ( ASA <B-Chemical> , 50 mg / kg , i . p . ) , a positive control , showed only 30 % inhibition .
```

Figure 12: tester les modèles sur des phrases différentes

# 5

---

## MODÈLE GÉNÉRALISÉ

Dans le but de pousser notre étude et expérimenter sur un corpus contenant les différentes thématiques abordées auparavant, nous avons décidé de créer un modèle entraîné sur un corpus regroupant les quatre thématiques. Le but est d'avoir un unique modèle capable de détecter les différents tags notamment : maladies, gènes et produits chimiques.

Le modèle Flair a été retenu pour cette tâche, suite à son résultat pertinent dans les corpus précédents ainsi l'intuitive de l'architecture de ce dernier.

EPOCH	LOSS	PRECISION	RECALL	F1
1	6.93	0.6386	0.4443	0.5240
10	3.22	0.7955	0.6725	0.7289
20	2.80	0.7664	0.7846	0.7754
50	2.54	0.7812	0.7929	0.7870
72	2.53	0.7820	0.7955	0.7887

Table 3: Résultats d'entraînement du modèle généralisé

Avec l'entraînement du modèle sur ce corpus généralisé, nous avons atteint un score F1 de 79%. Un score qui reste intéressant en prenant en considération la distribution des classes non équilibrées ainsi que le nombre important de tags différents présents dans le corpus construit.

Une autre manière de tester le modèle généralisé est d'essayer de tagger les features dans les mêmes phrases de figure(12). Ce que nous proposons dans la figure (13) [code](#).

Sentance : gene expression and NF-kappa B activation through CD28 requires reactive oxygen production by 5-lipoxygenase .  
-----  
Tagged : gene expression and NF-kappa <B-protein> B <E-protein> activation through CD28 <S-protein> requires reactive oxygen production by 5-lipoxygenase .  
-----  
Sentance : In the in vivo study , the administration ( 50 mg / kg , i . p . ) of TET and FAN in mice showed the inhibition of thrombosis by 55 % and 35 % , respectively , while acetylsalicylic acid ( ASA , 50 mg / kg , i . p . ) , a positive control , showed only 30 % inhibition .  
-----  
Tagged : In the in vivo study , the administration ( 50 mg / kg , i . p . ) of TET <B-Chemical> and FAN <B-Chemical> in mice showed the inhibition of thrombosis <B-Disease> by 55 % and 35 % , respectively , while acetylsalicylic <B-Chemical> acid <I-Chemical> ( ASA <B-Chemical> , 50 mg / kg , i . p . ) , a positive control , showed only 30 % inhibition .  
-----  
Sentance : OBJECTIVES : The United Kingdom Parkinson ' s Disease Research Group ( UKPDRG ) trial found an increased mortality in patients with Parkinson ' s disease ( PD ) randomized to receive 10 mg selegiline per day and L - dopa compared with those taking L - dopa alone .  
-----  
Tagged : OBJECTIVES : The United Kingdom Parkinson <B-Disease> ' <I-Disease> s <I-Disease> Disease <I-Disease> Research Group ( UKPDRG ) trial found an increased mortality in patients with Parkinson <B-Disease> ' <I-Disease> s <I-Disease> disease <I-Disease> ( PD <B-Disease> ) randomized to receive 10 mg selegiline <B-Chemical> per day and L <B-Chemical> - <I-Chemical> dopa <I-Chemical> compared with those taking L <B-Chemical> - <I-Chemical> dopa <I-Chemical> alone .

Figure 13: Exemples des phrases tagger avec le modèle généralisé

# 6

---

## AMÉLIORATION POSSIBLES

### 6.1 L'AJOUT DES FEATURES

Nous pouvons toujours trouver dans la littérature des techniques pour améliorer le score de la performance des modèles. L'ensemble des travaux effectués dans l'article [7], montre une réussite remarquable d'incrémenter le score F1 en ajoutant des features pour améliorer les performances d'un CRF. Ce que nous pouvons faire aussi dans notre cas.

Une autre approche consiste à faire varier l'architecture de BiLSTM-CRF pour essayer d'augmenter le degré de précision de moddèle. Ce dépôt git présente un ensemble des architectures `code`

### 6.2 CHANGEMENT D'ARCHITECTURE

L'une des architectures qui a donné des scores de performance remarquable environ 90% est BERT-BiLSTM-CRF-NER. Le lien suivant illustre les différents travaux présentés par les chercheurs `code`. La figure (14) présente l'architecture de ce modèle.

### 6.3 APPRENTISSAGE CONTINUÉE

Une autre approche proposée pour augmenter la performance de la détection des NER consiste à créer un **Meta-Modèle** qui regroupe le modèle *Flair*, *Spacy*, *CRF* et *BLSTM*. L'idée derrière ce regroupement est de donner la possibilité à chaque modèle d'apprendre en permanence en fonction des résultats des autres modèles. Nous pouvons mettre en place cette approche en implémentant les étapes suivantes :

- Le modèle prend comme entrée une phrase à tagger.
- La phrase en question passe par les trois modèles: *Flair*, *Spacy*, *CRF* et *BLSTM*
- Chaque modèle renvoie ces outputs.

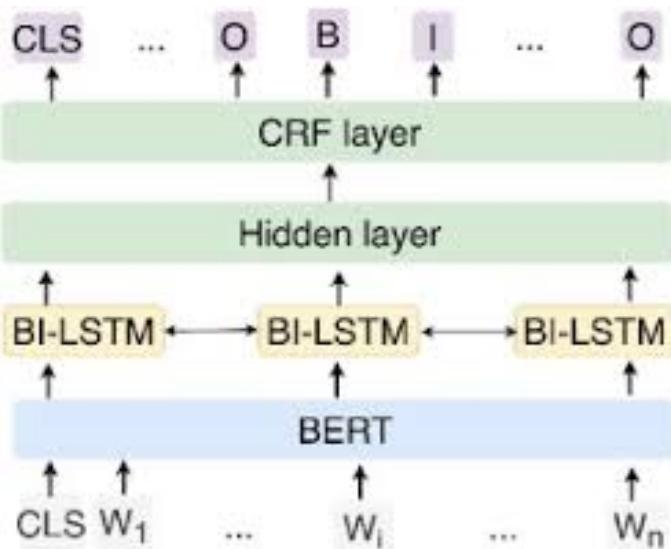


Figure 14: L'architecture Bert-CRF-BLSTM [9]

- L'algorithme sélectionne le modèle qui renvoie le meilleur tag.
- L'algorithme lance un reentraînement en utilisant l'output génère dans l'étape précédent comme donnée d'entraînement pour les autres modèles.

# 7

---

## CONCLUSION

Nous avons eu l'occasion de traiter une problématique très répondu dans les domaines de recherche de data science, plus précisément le domaine de NLP dans un cadre BioMedical. Durant ce projet, nous étions amenées à réaliser un NER sur des différentes thématiques BioMedical.

La richesse de ce domaine, nous a permis de découvrir, utiliser et expérimenter plusieurs architectures d'apprentissage automatique profond.

Nous avons constaté qu'il est toujours possible de combiner plusieurs architectures adaptées pour améliorer les performances des modèles. Une tâche importante d'un data scientist

Nous avons constaté qu'il est toujours possible de combiner plusieurs architectures adaptées pour améliorer les performances des modèles.

---

## REFERENCES

- [1] John Lafferty, Andrew McCallum, Fernando Pereira *Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data*. In Proceedings of the Eighteenth International Conference on Machine Learning (ICML-2001), 2001
- [2] Xuezhe Ma and Eduard Hovy *End-to-end Sequence Labeling via Bi-directional LSTM-CNNs-CRF*,  
2016
- [3] Eliyahu Kiperwasser,Yoav Goldberg *Simple and Accurate Dependency Parsing Using Bidirectional LSTM Feature Representations*,2016
- [4] Savelie Cornegruta, Robert Bakewell, Samuel Withey and Giovanni Montana,*Modelling Radiological Language with Bidirectional Long Short-Term Memory Networks*,2016
- [5] BERT Explained:State of the art language model for NLP,  
<https://towardsdatascience.com/bert-explained-state-of-the-art-language-model-for-nlp-f8b21a9b6270>
- [6] Alan Akbik, Duncan Blythe, Roland Vollgraf *Contextual String Embeddings for Sequence Labeling*
- [7] Hidayat Ur Rahman,Thomas Hahn,Dr. Richard Segall *Biomedical Disease Name Entity Recognition Using,NCBI Corpus*
- [8] <https://towardsdatascience.com/from-pre-trained-word-embeddings-to-pre-trained-language-models-focus-on-bert-343815627598>
- [9] <https://www.sciencedirect.com/science/article/abs/pii/S1386505619310068>
- [10] <https://spacy.io/usage/training>